

Part B: Ex1:

$D_1 = \text{"cat eat fish"}$, $D_3 = \text{"cat likes fish"}$

$D_2 = \text{"dog eat fish"}$

Vocab = [cat, dog, eats, fish, likes]

Count Vector τ : $D_1 = [1 \ 0 \ 1 \ 1 \ 0]$

$D_2 = [0 \ 1 \ 1 \ 1 \ 0]$

$D_3 = [1 \ 0 \ 0 \ 1 \ 1]$

Ex2: $\tau_f(\text{cat}, D_1) = \frac{1}{3}$, $\tau_f(\text{eats}, D_1) = \frac{1}{3}$, $\tau_f(\text{fish}, D_1) = \frac{1}{3}$

$$\tau_f(\text{term}, D) = \frac{c(\text{term}, D)}{\sum_{\text{term}} c(\text{term}, D)}$$

$$\sum_{\text{term}} \tau_f(\text{term}, D_1) = \frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$$

Ex3: IDF:

corpus có $N=3$ và $df(\text{cat})=2$, $df(\text{dog})=1$, $df(\text{eats})=2$,
 $df(\text{fish})=3$, $df(\text{likes})=1$.

$$idf(\text{cat}) = \log \frac{N}{df(\text{cat})} = \log \left(\frac{3}{2} \right), idf(\text{dog}) = \log \left(\frac{3}{1} \right)$$

$$idf(\text{eats}) = \log \frac{N}{df(\text{eats})} = \log \left(\frac{3}{2} \right)$$

$$idf(\text{fish}) = \log \left(\frac{3}{3} \right) = 0$$

$$idf(\text{likes}) = \log 3$$

term "fish" có giá trị IDF thấp nhất vì term fish xuất hiện ở cả 3 document cho thấy độ phân biệt của document chứa vào term này là 0 có ý nghĩa.

Ex4: TF-IDF:

$D_1 = \text{"cat eats fish"}$

$$\text{tf-idf}(\text{cat}) = \text{tf}(\text{cat}) \cdot \text{idf}(\text{cat}) = \frac{1}{3} \cdot \log(1.5) = 0.1332$$

$$\text{tf-idf}(\text{eats}) = \text{tf}(\text{eats}) \cdot \text{idf}(\text{eats}) = \frac{1}{3} \cdot \log(1.5) = 0.1332$$

$$\text{tf-idf}(\text{fish}) = \text{tf}(\text{fish}) \cdot \text{idf}(\text{fish}) = \frac{1}{3} \cdot 0 = 0$$

Ta thấy fish xuất hiện duy nhất ở các document $\Rightarrow$ nó có mang lại ý nghĩa hay việc phân loại các document này $\Rightarrow$ để thể hiện giá trị thì tf-idf của nó bằng 0.

Ex5: $x = [1, 1, 1]^T$, $y = [1, 1, 0]^T$

$$\cos(x, y) = \frac{x^T \cdot y}{\|x\|_2 \cdot \|y\|_2} = \frac{1 \cdot 1 + 1 \cdot 1}{\sqrt{3} \cdot \sqrt{2}} = \frac{2}{\sqrt{6}}$$

hai document giống nhau ở 2 trên 3 term nhưng cosine similarity ở độ tỷ lệ giống nhau mà độ góc giữa 2 vector này, hai góc cũng bé $\Rightarrow$ mức độ này đồng nghĩa 2 vector là cùng lân và gần lại.

Ex6: $D_1 = \text{"medical image classification"}$

$D_2 = \text{"medical image analysis"}$

$D_3 = \text{"natural language processing"}$

$Q = \text{"medical image classification"}$

1. Document D_1 có similarity với Q là cao nhất, đáng kể hơn D_2
2. Document D_3 có similarity với Q là thấp nhất, do Q có từ mà chúng không có
3. Term "medical" và "image" có thể có giá trị IDF thấp nhất vì nó xuất hiện ở 2 trên 3 documents.
4. nếu bỏ IDF và thay bằng cosine thì Q thay đổi vị trí này.