

$$P(\text{the cat eats}) = P(\text{the}) \cdot P(\text{cat}|\text{the}) \cdot P(\text{eats}|\text{the cat})$$

nếu $P(w_t | w_1, \dots, w_{t-1}) \Rightarrow$ số lượng context tăng cực nhanh $\Rightarrow$ do đó n-gram Language model sử dụng 1 giá trị để đếm ghi nhớ.

* Unigram: chỉ xét từ hiện tại:

$$P(w_t) \text{ từ } \lg P(w) = \frac{C(w)}{N} \rightarrow \text{số lần từ } (w) \text{ xuất hiện.}$$

$N \rightarrow$ tổng số token.

* Bigram: $P(w_t | w_{t-1})$.

$$\lg: P(w_t | w_{t-1}) = \frac{C(w_{t-1}, w_t)}{C(w_{t-1})}$$

* Trigram: $P(w_t | w_{t-2}, w_{t-1})$.

$$P(w_t | w_{t-2}, w_{t-1}) = \frac{C(w_{t-2}, w_{t-1}, w_t)}{C(w_{t-2}, w_{t-1})}$$

Bài 1: Unigram

1) vocab: [the, cat, eats, fish, likes, dog, meat]

2, tổng số token: 12.

$$3, P(\text{the}) = \frac{C(\text{the})}{12} = \frac{3}{12} = \frac{1}{4} \quad \left| \quad P(\text{fish}) = \frac{2}{12} = \frac{1}{6}$$

$$P(\text{cat}) = \frac{C(\text{cat})}{12} = \frac{2}{12} = \frac{1}{6} \quad \left| \quad P(\text{dog}) = \frac{1}{12}$$

$$4, \sum_w P(w) = \frac{1}{4} + P(\text{the}) + P(\text{cat}) + P(\text{eats}) + P(\text{fish}) + P(\text{likes}) + P(\text{dog}) + P(\text{meat})$$

$$= \frac{3}{12} + \frac{2}{12} + \frac{2}{12} + \frac{2}{12} + \frac{1}{12} + \frac{1}{12} + \frac{1}{12} = 1$$

$$\text{Bài 2: } P(\text{cat}|\text{the}) = \frac{P(\text{the cat})}{P(\text{the})} = \frac{1}{3}, \quad P(\text{dog}|\text{me}) = \frac{P(\text{me dog})}{P(\text{me})} = \frac{1}{3}$$

$$P(\text{eats}|\text{cat}) = \frac{P(\text{cat eats})}{P(\text{cat})} = \frac{1}{2}, \quad P(\text{likes}|\text{cat}) = \frac{P(\text{cat likes})}{P(\text{cat})} = \frac{1}{2}$$

* các từ trong xác suất các từ sau đó phải bằng 1 vì

$$\sum_{w \in V} P(w | the) = \frac{\sum_{w \in V} \text{Count}(the, w)}{\sum_{w \in V} \text{Count}(the)}$$

vì trong corpus mỗi lần xuất hiện cả từ "the" đều được nối tiếp bởi 1 từ cụ thể, nên tổng số lần xuất hiện của tất cả các cặp (the, w) = tổng số lần xuất hiện của từ "the"

$$\sum_{w \in V} P(w, "the") = \sum_{w \in V} \frac{C("the", w)}{C("the")} = \frac{C("the")}{C("the")} = 1$$

cụ thể trong corpus sau "the" chỉ có "cat" và "dog"

$$P(cat | the) + P(dog | the) = \frac{2}{3} + \frac{1}{3} = 1$$

Bài 3: Xác suất câu: "the cat eats fish" = S_1 .

$$P(S_1) = P(the) \cdot P(cat | the) \cdot P(eats | cat) \cdot P(fish | eats)$$

$$\text{vì } P(the) = \frac{C(the)}{N} = \frac{3}{12} = \frac{1}{4}$$

$$P(cat | the) = \frac{2}{3}, \quad P(eats | cat) = \frac{1}{2}, \quad P(fish | eats) = \frac{1}{2}$$

$$P(fish | eats) = \frac{C(eats, fish)}{C(eats)} = \frac{1}{2}$$

$$P(S_1) = \frac{1}{4} \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{2}{48} = \frac{1}{24} \approx 0.04167$$

* nếu thêm một từ vào câu xác suất cả câu x hay từ tăng:

$$P(w_1, \dots, w_{n+1}) = P(w_1, \dots, w_n) \cdot P(w_{n+1} | w_n)$$

$$\text{vì } 0 < P(w_{n+1} | w_n) \leq 1$$

$\Rightarrow$ nhân với 1 số nhỏ hơn 1 sẽ làm xác suất của cả câu giảm đi.

No. _____

Date _____

Bài 4: sentence ranking

$S_1 = \text{the cat eats fish.}$

$S_2 = \text{the dog eats fish.}$

$$P(S_1) = P(\text{the}) \cdot P(\text{cat} | \text{the}) \cdot P(\text{eats} | \text{cat}) \cdot P(\text{fish} | \text{eats})$$

$$P(S_2) = P(\text{the}) \cdot P(\text{dog} | \text{the}) \cdot P(\text{eats} | \text{dog}) \cdot P(\text{fish} | \text{eats})$$

$\Rightarrow$ muốn nêu ra chỉ cần so sánh.

$$t_1 = P(\text{cat} | \text{the}) \cdot P(\text{eats} | \text{cat}) = \frac{2}{3} \cdot \frac{1}{2} = \frac{1}{3}$$

$$t_2 = P(\text{dog} | \text{the}) \cdot P(\text{eats} | \text{dog}) = \frac{1}{3} \cdot 1 = \frac{1}{3}$$

$\Rightarrow$ hai câu có xác suất bằng nhau.

$$P(S_1) = P(S_2) \quad \times$$

Bài tập Smoothing

$$P_{\text{laplace}}(w|h) = \frac{C(h,w) + 1}{C(h) + |V|}$$

vì: $C(\text{cat}) = 10$, $C(\text{cat eats}) = 0$, $V = 5$:

$$P_{\text{laplace}}(\text{eats} | \text{cat}) = \frac{C(\text{cat eats}) + 1}{C(\text{cat}) + |V|} = \frac{1}{15} \quad \text{Ktr.}$$

vì $C(\text{cat} \times \text{eats}) = 3$.

$$P_{\text{laplace}}(\text{eats} | \text{cat}) = \frac{3+1}{10+5} = \frac{4}{15}$$

$$\text{ta có } \sum_{w \in V} P(w|h) = 1$$

đề cấp 1 việc xác suất dương (>0) cho các bigram chưa từng xuất hiện, mô hình buộc phải ký kết khả năng xác suất từ các bigram có tần số 0.

No. _____

Date _____

perplexity: $P(w_1) = 0.5$, $P(w_2|w_1) = 0.25$, $P(w_3|w_2) = 0.5$.

$$P(w) = P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_2)$$

$$P(w) = 0.5 \cdot 0.25 \cdot 0.5 = 0.0625$$

$$PP(w) = P(w)^{-\frac{1}{N}} = \sqrt[N]{\frac{1}{P(w)}}$$

$$\text{Với } N=3: PP(w) = \left(\frac{1}{16}\right)^{-\frac{1}{3}} = (16)^{\frac{1}{3}} = \sqrt[3]{16} \approx 2.5198$$

2, ở đây khi $P(w_2|w_1) = 0.1$.

$$P(w) = 0.5 \cdot 0.1 \cdot 0.5 = 0.025$$

$$PP(w) = (0.025)^{-\frac{1}{3}} = (40)^{\frac{1}{3}} = \sqrt[3]{40} \approx 3.41995$$

xác suất nhỏ càng làm tăng giá trị perplexity.

* hàm số $f(x) = \frac{1}{x}$ tăng rất nhanh khi $x \rightarrow 0$.

+ có thể nhận thấy: nếu xác suất bị giảm $\Rightarrow$ kéo theo tăng khối lượng dữ liệu cũng sẽ bị giảm.