

Prediction 1: Khi chuyển unigram $\rightarrow$ bigram $\rightarrow$ trigram vocabulary $\approx$ tăng.

Prediction 2: số lượng n -gram duy nhất (unique n -grams) sẽ tăng mạnh; không gian mang tính lý thuyết tăng theo hàm mũ ($|V|^n$).

Prediction 3: mô hình n -gram sẽ có khả năng gặp zero probability cao nhất.

Prediction 4: mô hình n -gram sẽ có khả năng có perplexity thấp hơn trên training set.

Reasons: ngữ cảnh càng nhiều thì mô hình càng tốt vs dữ liệu huấn luyện.
tri-gram ghi nhớ context mức 3 từ $\rightarrow$ perplexity thấp vs training sẽ nhỏ hơn.
confidence: 90%.

bổ sung: Prediction 1: Reasons: vocabulary $|V|$ là tập hợp các từ distinct trong corpus $\rightarrow$ khái niệm từ vocabulary $\approx$ bị máy tính nếu ta xét của số từ ngữ cảnh là 1, 2 hay 3 từ.
confidence: 100%.

Prediction 2: Reasons: số lượng từ ghép (2 và 3) luôn duy định hơn nhiều so với số từ 1.
confidence: 95%.

Prediction 3: Reasons: đầu tiên rằng một ngữ cảnh càng dài (n_i-1, n_i-1) gồm từ đồng nghĩa, xuất phát từ các gặp chuỗi chuỗi số 3 từ là (-) đó đều luôn có mặt.
confidence: 99%.

Prediction 5: prediction: chắc chắn từ n -gram sẽ ~~khác~~ hơn n -gram trên test set.

Reason: khi corpus nhỏ, hầu hết cụm 3 từ chỉ xuất hiện 1 lần hoặc 0 xuất hiện. n -gram sẽ bị overfit nghiêm trọng nên tập training sẽ gặp lại zero probability đây đều nên dữ liệu mới $\rightarrow$ performance sẽ rất kém hơn n -gram.

confidence: 95%