Prediction:

Prediction 1: Nếu 1 key có dot product lớn hơn các key khác, attention weight của nó sẽ như thế nào.

predict: key đó sẽ có attention weight lớn hơn

Reason: Softmax biến score thành xác suất weight score càng lớn. mũ $e^{score}$ càng lớn $\Rightarrow$ weight càng lớn.

confidence = 95%

Prediction 2: cho $s = [1, 1, 1, 1]$ ~~X~~.

$\Rightarrow \alpha = [0.25, 0.25, 0.25, 0.25]$.

predict: Attention sẽ phân bố đều cho các ~~token~~ token có các tokens.

Reason: không có key nào có score cao hơn key khác.

confidence: 100%

Prediction 3: cho $s = [1, 1, 10]$, score $s[3]$ ± 10 lớn hơn rất nhiều.

prediction: attention tập trung hoàn toàn vào token thứ 3:

Reason: Softmax: $\alpha_i = \frac{e^{s_i}}{\sum_j e^{s_j}}$ vì $e^{10} >> e^1$

$\Rightarrow$ attention tập trung vào phần tử thứ 3.

confidence: 98%

prediction 4: nếu tăng sequence từ 10 tokens $\rightarrow$ 1000 tokens chi phí tính toán thay đổi như sau:

với Self-attention: $Q \cdot K^T$ có kích thước $n \times n$.

$\Rightarrow O(n^2)$

TAKEYO
タケヨ

No.
Date

từ 10 tokens → 1000 tokens = $\frac{1000^2}{10^2} = 10\,000$

⇒ số lượng score cần tính có thể tăng khoảng 10 000 lần.

Predictions: Attention quan chọn đúng token mà con người cho là quan trọng nhất không

prediction: không.

Reason: attention weight được xác định dựa trên:

- Query, key, cách mô hình học được biểu diễn, mục tiêu training.

⇒ attention cao ≠ đúng nghĩa với việc token đó là "quan trọng nhất" theo cách con người giải thích

Confidence: 99%.

Scaled dot-product Attention:

Bài tập: $d_k = 4$, và $Q.K^T = [4, 2, 0]$

Scaled scores = $\frac{Q.K^T}{\sqrt{d_k}} = \frac{[4,2,0]}{\sqrt{4}} = [2, 1, 0]$.

Soft max ([2, 1, 0]) = [0.6652, 0.2447, 0.0900]).

Không scaling

soft max ([4, 2, 0]) = [0.8668, 0.1173, 0.0159]).

Scaling làm sự phân bố của Score của các từ trở nên mềm hơn, ~~hợp lý~~

Temperature:

Tự sử dụng: Soft max $\left(\frac{S}{T}\right)$.

với $S = [1, 2, 3]$ và thử $T = [0.5, 1.0, 2.0]$

entropy = $-\sum_i p_i \cdot \log(p_i)$.

TAKEYO
タケヨ