+ Reflection:

RNN, LSTM, GRU: là các mô hình recurrent xử lý sequence theo thứ

tự: $x_1 \to x_2 \to x_3 \to x_4, \dots \to x_T$

hidden state = $h_t = f(x_t, h_{t-1})$.

⇒ thứ tự của sequence đóng vai trò trực tiếp (s) quá trình tính toán.

Attention: cũng có thể xử lý sequence order, nhưng bản thân

attention, không nhất thiết có cơ chế recurrence.

VD: self-attention tính: $Q.K^T$

cho các phép token tương tác trực tiếp vs nhau.

+ hidden state:

RNN, LSTM, GRU có hidden state: h_t đc cập nhật thông

qua timestamp.

attention o bắt buộc phải duy trì một hidden state recurrent dy nhất

thay vào đó nó tạo context bằng weighted combination.

$$c = \sum_i \alpha_i \cdot v_i$$

* Sequential computation:

RNN: $h_t = f(\cancel{h_t}\ h_{t-1}, x_t)$

nên phải tính: $h_0 \to h_1 \to h_2 \to \dots h_T$.

⇒ hạn chế khả năng song song

Attention có thể tính các query, key, interactions cùng lúc thông qua matrix multiplications:

$$Q \cdot K^T.$$

⇒ phù hợp nhất vs GPU và song song hoá.